

Gradient Boosting Regressor

FUNDAMENTOS, MECÁNICA ALGORÍTMICA Y ECUACIONES FUNDAMENTALES

El método de **Gradient Boosting (Gradiente Descendiente Generalizado)** para regresión es uno de los algoritmos de Machine Learning más potentes y utilizados en la actualidad. A diferencia de los modelos que entrenan árboles independientes en paralelo (como Random Forest), Gradient Boosting construye los árboles de forma **secuencial**, donde cada nuevo árbol tiene la misión exclusiva de corregir los errores cometidos por los árboles anteriores.

1. Intuición Sencilla: La Metáfora del Golfista

Imagina que estás jugando al golf y quieres meter la bola en el hoyo:

- El **Primer Golpe (Árbol 1)**: Haces un tiro inicial robusto. La bola avanza mucho pero no cae exactamente en el hoyo; queda a una distancia de 30 metros (este es el *residuo* o error).
- El **Segundo Golpe (Árbol 2)**: En lugar de volver a tirar desde el inicio, te paras donde quedó la bola y golpeas apuntando exclusivamente a cubrir esos 30 metros faltantes. Te desvías por 3 metros.
- El **Tercer Golpe (Árbol 3)**: Apuestas solo a corregir esos 3 metros restantes.

Al final, tu predicción total no es el resultado de un solo súper golpe, sino de la **suma acumulada** de todos los golpes correctivos.

2. ¿Cuál es la Ecuación que Ajusta?

Matemáticamente, Gradient Boosting construye una función predictiva final $F_M(x)$ que es una combinación lineal de múltiples modelos base débiles (usualmente árboles de decisión cortos o 'stumps').

La ecuación general de predicción para un modelo con M árboles es:

$$F_M(x) = F_0(x) + \nu \sum_{m=1}^M \gamma_m h_m(x)$$

Donde cada componente significa:

- $F_0(x)$: **Predicción inicial base**. Para la pérdida por mínimos cuadrados, es simplemente el valor promedio de la variable objetivo de todo el dataset original: $F_0(x) = \operatorname{argmin}_\gamma \sum L(y_i, \gamma)$.
- $h_m(x)$: **El Árbol de Regresión actual (m)**. Es el modelo matemático entrenado en el paso m enfocado en predecir los pseudoresiduos (el error del paso anterior).

- γ_m : **El valor terminal o factor de escala**. Es el ajuste óptimo asignado a las hojas del árbol m para minimizar la función de pérdida global.
- ν (nu): **Tasa de aprendizaje (Learning Rate)**. Un hiperparámetro crucial (entre 0 y 1) en Scikit-Learn (`learning_rate`) que escala la contribución de cada árbol para evitar el sobreajuste (overfitting). Actúa como un atenuador de pasos.

3. El Algoritmo Paso a Paso en Scikit-Learn

El término "*Gradient*" (Gradiente) proviene del hecho de que el algoritmo calcula la derivada de una función de pérdida (por defecto, el Error Cuadrático Medio o MSE) para saber en qué dirección y magnitud ajustar el siguiente árbol.

Paso 1: Inicialización

Se inicializa el modelo con una constante que minimice la pérdida total. En regresión con MSE, equivale a predecir la media para todas las observaciones.

Paso 2: Bucle Secuencial (Para $m = 1$ hasta M)

A) Calcular los residuos (Gradientes negativos): Para cada dato de entrenamiento i , se calcula la diferencia exacta entre el valor real y_i y la predicción acumulada actual $F_{m-1}(x_i)$.

B) Ajustar un nuevo árbol: Se entrena un árbol de decisión $h_m(x)$ usando las variables predictoras x , pero intentando predecir los residuos obtenidos en el inciso A, no la variable original y .

C) Actualizar el modelo combinado: Se suma la nueva predicción atenuada por la tasa de aprendizaje a la ecuación acumulada: $F_m(x) = F_{m-1}(x) + \nu \gamma_m h_m(x)$.

Paso 3: Predicción Final

Cuando llega un dato nuevo, pasa secuencialmente por todos los M árboles generados y los resultados se agregan linealmente para entregar el valor continuo final.

4. Parámetros clave en Sklearn para Controlar el Ajuste

- `n_estimators` : El número total de árboles a construir (M). Un número muy alto provoca sobreajuste.

- `learning_rate` : Reduce el impacto de cada árbol individual (v). Existe un compromiso (trade-off) directo: a menor tasa de aprendizaje, se requerirán más estimadores (`n_estimators`) para alcanzar la convergencia óptima.
- `max_depth` : Limita la profundidad de cada árbol (usualmente valores pequeños como 3 a 5 son suficientes para que actúen como estimadores débiles pero eficientes).