

Guía de Interpretación Estadística y Toma de Decisiones

Análisis Didáctico de Reportes de Regresión Lineal Múltiple (OLS)

Este documento constituye una bitácora científica y didáctica diseñada para desglosar, interpretar y traducir a decisiones estratégicas cada sección del reporte de regresión por Mínimos Cuadrados Ordinarios (OLS) provisto por la librería statsmodels de Python.

1. El Reporte Original de Statsmodels

A continuación se presenta el bloque de datos bajo análisis, correspondiente a un modelo con una variable dependiente (*y*) y cuatro variables explicativas o predictoras (*x1*, *x2*, *x3*, *x4*):

OLS Regression Results						
=====						
Dep. Variable:	y	R-squared:	0.974			
Model:	OLS	Adj. R-squared:	0.974			
Method:	Least Squares	F-statistic:	3729.			
Date:	Sat, 27 Jun 2026	Prob (F-statistic):	3.77e-312			
Time:	15:36:29	Log-Likelihood:	-289.16			
No. Observations:	400	AIC:	588.3			
Df Residuals:	395	BIC:	608.3			
Df Model:	4					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	-89.0981	8.792	-10.134	0.000	-106.383	-71.814
x1	72.0068	4.849	14.850	0.000	62.474	81.540
x2	-14.0481	0.969	-14.499	0.000	-15.953	-12.143
x3	0.9032	0.067	13.552	0.000	0.772	1.034
x4	74.4907	10.399	7.163	0.000	54.046	94.936
=====						
Omnibus:	1.116	Durbin-Watson:	1.710			
Prob(Omnibus):	0.572	Jarque-Bera (JB):	0.897			
Skew:	-0.038	Prob(JB):	0.638			
Kurtosis:	3.219	Cond. No.	5.77e+04			
=====						

2. Sección Superior: Bondad de Ajuste y Estadísticos Globales

Esta primera sección mide la arquitectura general del modelo, evaluando si las variables elegidas logran explicar el fenómeno de manera conjunta y qué tan eficiente es dicha explicación.

Término	Valor Actual	Significado / Interpretación Didáctica	Conclusión y Decisión
Dep. Variable	y	Variable dependiente, respuesta o criterio. Es el fenómeno cuantitativo que se desea predecir o explicar.	Confirmación del vector objetivo.
R-squared (R^2)	0.974	Coeficiente de determinación. Indica la proporción de la varianza total de y explicada por el modelo. Aquí, el 97.4% de la variabilidad de y se explica por x1, x2, x3 y x4.	Conclusión: El ajuste es excepcionalmente alto. Las variables capturan casi la totalidad del comportamiento del fenómeno. Decisión: Modelo altamente confiable para predicción directa.
Adj. R-squared (R^2_{adj})	0.974	R^2 corregido por el número de predictores y tamaño de muestra. Penaliza la inclusión de variables irrelevantes. Al ser idéntico al R^2 original, ratifica que no hay variables de "relleno".	Conclusión: El modelo es eficiente y equilibrado; la densidad de variables está perfectamente justificada por su aporte informacional.
F-statistic / Prob (F-statistic)	3729 / 3.77e-312	Prueba F global. Evalúa la hipótesis nula (H_0) de que todos los coeficientes de las pendientes son iguales a cero. El p-valor (3.77×10^{-312}) es prácticamente cero.	Conclusión: El modelo en su conjunto es altamente significativo de forma estadística. Decisión: Se rechaza plenamente H_0 . El conjunto de predictores posee un poder explicativo real y robusto.
Log-Likelihood	-289.16	Logaritmo de la función de verosimilitud. Mide qué tan probable es observar los datos actuales dado el modelo ajustado. Valores más altos (menos negativos) indican mejor ajuste.	Utilizado principalmente para comparar este modelo contra versiones alternativas (ej. si elimináramos x4).
AIC / BIC	588.3 / 608.3	Criterios de Información de Akaike y Bayesiano. Evalúan el balance entre precisión y complejidad (parsimonia). Valores más bajos indican un modelo preferible.	Decisión: Conservar estos valores como métricas de referencia. Si se propone un modelo alternativo, se elegirá el que reduzca estos indicadores.
Df Residuals / Model	395 / 4		

Término	Valor Actual	Significado / Interpretación Didáctica	Conclusión y Decisión
		Grados de libertad de los residuos ($N - K - 1$) y del modelo (K , número de predictores sin la constante). Muestra que tenemos una muestra amplia en relación al número de parámetros.	Garantiza la estabilidad matemática del cálculo estadístico.

Diagnóstico Global del Modelo

Los indicadores macro demuestran que estamos ante un modelo predictivo de altísimo rendimiento. La coincidencia exacta entre el R^2 y el R^2 Ajustado en un nivel del 97.4% sugiere una óptima selección de variables con suficiente volumen muestral ($N = 400$).

3. Sección Central: Coeficientes e Indicadores Individuales

Esta tabla nos permite descender al nivel micro para examinar el impacto específico, la dirección, la magnitud y la significancia estadística de cada variable explicativa de forma aislada, manteniendo las demás constantes (ceteris paribus).

Variable	coef	std err	t	P > t (p-value)	[0.025 - 0.975] (IC 95%)
const	-89.0981	8.792	-10.134	0.000	[-106.383, -71.814]
x1	72.0068	4.849	14.850	0.000	[62.474, 81.540]
x2	-14.0481	0.969	-14.499	0.000	[-15.953, -12.143]
x3	0.9032	0.067	13.552	0.000	[0.772, 1.034]
x4	74.4907	10.399	7.163	0.000	[54.046, 94.936]

Metodología de Análisis Individual:

- **coef (Efecto Marginal):** Determina el cambio promedio en y ante un incremento unitario en la variable independiente correspondiente. Por ejemplo, si x_1 aumenta en 1 unidad, y incrementa en 72.00 unidades. Si x_2 aumenta en 1 unidad, y decrece en 14.04 unidades.
- **std err (Error Estándar):** Mide la variabilidad e incertidumbre del coeficiente calculado. Entre más pequeño sea en relación al coeficiente, más preciso es el cálculo.
- **Estadístico t y p-valor ($P > |t|$):** Evalúan si el impacto de la variable es puramente aleatorio. Un $p\text{-valor} < 0.05$ rechaza la hipótesis de que la variable no afecta a y . En este reporte, **todas las variables son críticamente significativas ($p = 0.000$)**.
- **Intervalo de Confianza (IC 95%):** Rango donde se encuentra el verdadero coeficiente poblacional con un 95% de certeza. Si el intervalo no cruza el cero (0), la variable es estadísticamente significativa de manera inequívoca.

4. Sección Inferior: Diagnósticos de Residuos e Inferencia Matemática

Para asegurar que las conclusiones previas no sean sesgadas o artificiales, es imperativo comprobar los supuestos clásicos del modelo lineal sobre los errores (residuos).

• Normalidad de los Residuos:

- *Omnibus (1.116) / Prob(Omnibus) (0.572)*: La hipótesis nula plantea que los residuos se distribuyen normalmente. Al ser el p-valor mayor a 0.05 (57.2%), **no podemos rechazar la normalidad**.
- *Jarque-Bera (JB) (0.897) / Prob(JB) (0.638)*: Otra prueba robusta de normalidad. Al arrojar un p-valor del 63.8%, se ratifica de forma contundente que los errores se comportan de manera simétrica y normal.
- *Skew (Sesgo = -0.038) y Kurtosis (Curtosis = 3.219)*: El sesgo está extremadamente cercano a 0 (simetría perfecta) y la curtosis ronda el valor de 3 (distribución mesocúrtica estándar). Los residuos son limpios y estables.

• Independencia / No Autocorrelación:

- *Durbin-Watson (1.710)*: Mide la correlación entre residuos adyacentes. El indicador oscila entre 0 y 4. Un valor de 2 significa ausencia total de autocorrelación. Al situarse en 1.710, está dentro de la zona segura de aceptación (usualmente entre 1.5 y 2.5), indicando que no hay patrones de dependencia temporal o secuencial entre las observaciones.

Alerta Crítica: Nota de Advertencia sobre Multicolinealidad

Condition Number (Cond. No. = 5.77e+04): El número de condición mide la sensibilidad del modelo a pequeños cambios en los datos. Un valor superior a 30 indica presencia latente de multicolinealidad (variables independientes fuertemente correlacionadas entre sí). Un valor de 57,700 es un indicador severo de que existe redundancia de información entre algunas de las variables independientes (x_1 , x_2 , x_3 , x_4).

5. Conclusiones y Plan de Acción / Decisiones Operativas

A pesar del excelente desempeño métrico del modelo, la presencia de un Número de Condición elevado exige acciones analíticas correctivas inmediatas para mitigar riesgos de inestabilidad en los coeficientes.

Conclusiones Clave:

1. **Capacidad Predictiva Excepcional**: El modelo explica el 97.4% de la varianza del fenómeno objetivo. Es apto para su integración en sistemas de planeación operativa y analítica prescriptiva.
2. **Efectos Claros y Direccionales**: Se detectaron dos aceleradores potentes de la variable objetivo (x_4 con +74.49 y x_1 con +72.00), un estabilizador fino (x_3 con +0.90) y un detractor de escala (x_2 con -14.04).
3. **Cumplimiento de Supuestos Lineales**: Los errores son independientes y normales, lo que valida formalmente las pruebas t y F ejecutadas.

Plan de Decisiones y Pasos a Seguir:

Para corregir la alerta de multicolinealidad advertida en la nota del reporte, se debe ejecutar la siguiente secuencia en el entorno de desarrollo:

1. **Calcular el Factor de Inflación de la Varianza (VIF)**: Ejecutar un análisis de correlación cruzada y calcular el VIF para cada variable. Un **VIF > 5 o 10** delatará formalmente cuál variable es matemáticamente redundante.

2. Depuración o Regularización:

- Si dos variables miden conceptos análogos (ej. Ingresos y Capacidad de Gasto), evaluar la eliminación de la variable con menor justificación teórica.
- Si todas las variables son operativamente indispensables, transicionar el entrenamiento hacia técnicas de regularización lineal como **Ridge Regression** o **Lasso Regression** para estabilizar los coeficientes numéricos ante el alto Número de Condición.