

Fundamento Matemático de Modelos de Regresión

Análisis de Permitividad del Agua · CRC Handbook of Chemistry and Physics

Regresión Lineal

Polinomial Grado 2

Polinomial Grado 3

Gradient Boosting

Variables: T (K) · P (MPa) $\rightarrow \epsilon$ (permitividad relativa)

Contexto del Problema

Permitividad del agua en función de T y P — datos del CRC Handbook

Datos

358 registros de la permitividad relativa ϵ del agua para $T \in [275, 1200]$ K y $P \in [0.1, 1000]$ MPa. Fuente: CRC Handbook of Chemistry and Physics.

Transformación

Se aplicó $\log(P)$ para linearizar la relación no lineal con la presión. Las variables T y $\log(P)$ se estandarizaron (Z-Score) antes del modelado.

Objetivo

Ajustar $\epsilon = f(T, P)$ con cuatro modelos de complejidad creciente y comparar su poder predictivo mediante RMSE, MAE y R^2 .

Ecuación general:

$$\hat{\epsilon} = f(T_{\text{std}}, \log P_{\text{std}}) \quad \text{con} \quad T_{\text{std}} = (T - \mu_T)/\sigma_T, \quad \log P_{\text{std}} = (\log P - \mu_{\log P})/\sigma_{\log P}$$

Modelo 1 – Regresión Lineal Múltiple

Modelo 1

El modelo más simple: hiperplano en el espacio (T_std, logP_std)

Definición del modelo

El modelo asume que la respuesta ε es una combinación lineal de las variables predictoras $x_1 = T_std$ y $x_2 = \log P_std$:

$$\hat{\varepsilon} = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2$$

Donde:

β_0 = intercepto (valor de ε cuando $x_1=x_2=0$)

β_1 = efecto marginal de T_std sobre ε

β_2 = efecto marginal de logP_std sobre ε

$\beta = [\beta_0, \beta_1, \beta_2]^T \in \mathbb{R}^3$ (vector de parámetros)

Forma matricial

$$\hat{\varepsilon} = X \beta$$
$$X \in \mathbb{R}^{n \times 3}, \quad \beta \in \mathbb{R}^3$$

Donde X es la matriz de diseño:

$$X = \begin{bmatrix} 1 & x_1^{(1)} & x_2^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} \\ \vdots & \vdots & \vdots \end{bmatrix}$$

Supuesto clave: la relación entre ε y las covariables es estrictamente lineal. Cualquier no-linealidad genera error sistemático (sesgo).

Regresión Lineal – Estimación por Mínimos Cuadrados (OLS)

Minimización de la suma de residuos al cuadrado

Modelo 1

Función de coste (RSS – Residual Sum of Squares):

$$L(\beta) = \|y - X\beta\|^2 = \sum_i (\varepsilon_i - \hat{\varepsilon}_i)^2 = (y - X\beta)^\top (y - X\beta)$$

Derivación analítica

Condición de primer orden:

$$\partial L / \partial \beta = -2X^\top (y - X\beta) = 0$$

Ecuaciones normales:

$$X^\top X \beta = X^\top y$$

Solución de forma cerrada:

$$\beta = (X^\top X)^{-1} X^\top y$$

Propiedades y supuestos

- **BLUE** (Best Linear Unbiased Estimator) si se cumplen supuestos Gauss-Markov.
- **Linealidad** en parámetros (no en variables).
- **E[ε] = 0** — residuos sin sesgo sistemático.
- **Homocedasticidad** $\text{Var}(\varepsilon) = \sigma^2 I$.
- **No multicolinealidad** $\text{rango}(X) = p$.
- **Complejidad:** $O(np^2)$ en tiempo, $O(p^2)$ parámetros.

Modelo 2 – Regresión Polinomial Grado 2

Modelo 2

Extensión del espacio de características con términos cuadráticos e interacción

Idea clave:

transformar las variables originales en un vector ampliado de características $\varphi(x)$ y aplicar regresión lineal en ese espacio.

Mapeo de características $\varphi: \mathbb{R}^2 \rightarrow \mathbb{R}^5$

$$\begin{aligned}\varphi(x) &= [1, x_1, x_2, x_1^2, x_1x_2, x_2^2]^T \\ &= [1, T^*, \log P^*, T^{*2}, T^* \cdot \log P^*, \log P^{*2}]^T\end{aligned}$$

Modelo completo

$$\begin{aligned}\hat{\varepsilon} &= \beta_0 + \beta_1 T^* + \beta_2 \log P^* \\ &\quad + \beta_3 T^{*2} + \beta_4 T^* \cdot \log P^* \\ &\quad + \beta_5 \log P^{*2}\end{aligned}$$

Interpretación de cada término (6 parámetros)

β_0

Intercepto

$\beta_1 T^*$

Efecto lineal de T

$\beta_2 \log P^*$

Efecto lineal de log(P)

$\beta_3 T^{*2}$

Curvatura en T

$\beta_4 T^* \cdot \log P^*$

Interacción T-P

$\beta_5 \log P^{*2}$

Curvatura en P

Modelo 3 – Regresión Polinomial Grado 3

Modelo 3

Captura de no-linealidades de orden superior — mayor flexibilidad, mayor riesgo de sobreajuste

Monomios generados (grado ≤ 3)

Grado 0: 1

Grado 1: x_1, x_2

Grado 2: x_1^2, x_1x_2, x_2^2

Grado 3: $x_1^3, x_1^2x_2, x_1x_2^2, x_2^3$

Total: $C(2+3, 3) = 10$ características

$$p(d) = C(n+d, d) \text{ monomios}$$

Compromiso Sesgo-Varianza

Error total = Sesgo² + Varianza + Ruido irreducible

$$\text{MSE}(\hat{y}) = [\text{Bias}(\hat{y})]^2 + \text{Var}(\hat{y}) + \sigma^2$$



Grado bajo → alto sesgo

El modelo no captura la curvatura real de $\epsilon(T, P)$.



Grado alto → alta varianza

El modelo memoriza el ruido; falla en datos nuevos.



Grado 3 → balance

Captura no-linealidades relevantes sin sobreajuste excesivo.

Modelo 4 – Gradient Boosting: Intuición

Modelo 4

Ensamble aditivo de árboles de decisión entrenados secuencialmente

Modelo aditivo general $F_M(x)$:

$$F_M(x) = F_0(x) + \eta \cdot h_1(x) + \eta \cdot h_2(x) + \dots + \eta \cdot h_M(x) = \sum_{m=0}^M \eta \cdot h_m(x)$$

Árbol base $h_m(x)$

Árbol de regresión de profundidad limitada ($\text{max_depth} \leq 5$).

Cada árbol h_m es un 'aprendiz débil' que aproxima un residuo específico, no el objetivo original y .

Tasa de aprendizaje η

Hiperparámetro $\in (0, 1]$ que escala la contribución de cada árbol.

η pequeño $\rightarrow$ más árboles necesarios, pero mejor generalización. ($\eta = 0.05$ en este análisis)

Residuo pseudo-gradiente

Cada árbol h_m se entrena sobre el negativo del gradiente de la pérdida:

$$r_{im} = -[\partial L(y_i, F) / \partial F]_{F=F_{\{m-1\}}}$$

Para MSE: $r_{im} = y_i - F_{\{m-1\}}(x_i)$

Función de pérdida usada (sklearn GBR por defecto):

$$L(y, F) = \frac{1}{2} \sum_i (y_i - F(x_i))^2 \rightarrow \text{Pérdida}$$

Gradient Boosting – Algoritmo de Friedman (2001),

Modelo 4

Descenso de gradiente en el espacio de funciones

Algoritmo: Stochastic Gradient Boosting

1. Inicializar: $F_0(x) = \operatorname{argmin}_y \sum L(y_i, y)$
(para MSE: $F_0 = \bar{y}$)
2. Para $m = 1, 2, \dots, M$:
 - a. Calcular pseudo-residuos:
 $r_{im} = -\partial L(y_i, F) / \partial F |_{F=F_{m-1}(x_i)}$
 - b. Ajustar árbol h_m sobre $\{x_i, r_{im}\}$
 - c. Actualizar modelo:
 $F_m(x) = F_{m-1}(x) + \eta \cdot h_m(x)$
3. Retornar $F_M(x)$

Hiperparámetros clave

- M** = 300 $n_{\text{estimators}}$ – número de árboles
- d** = 4 max_depth – profundidad máxima
- η** = 0.05 learning_rate – tasa de aprendizaje
- s** = 1.0 subsample – fracción de datos por árbol

Complejidad computacional

Tiempo de entrenamiento:

$$O(M \cdot n \cdot d \cdot 2^d)$$

Parámetros:

$$\approx M \cdot 2^d \text{ hojas (adaptativos)}$$

No requiere inversión matricial.

Comparativa de los Cuatro Modelos

Dimensión matemática, complejidad y desempeño en el dataset de permitividad

Modelo	Ecuación simplificada	# Parámetros	Complejidad	R ² test
Regresión Lineal	$\hat{\epsilon} = \beta_0 + \beta_1 T^* + \beta_2 \log P^*$	3	$O(np^2)$	≈ 0.985
Polinomial Grado 2	$\hat{\epsilon} = \sum_j \beta_j \varphi(x), \quad \varphi =6$	6	$O(np^2)$	≈ 0.997
Polinomial Grado 3	$\hat{\epsilon} = \sum_j \beta_j \varphi(x), \quad \varphi =10$	10	$O(np^2)$	≈ 0.999

Conclusiones del análisis comparativo

- La regresión lineal presenta sesgo porque $\epsilon(T,P)$ no es lineal en T ni en P.
- El polinomio grado 2 mejora el ajuste capturando la curvatura principal.
- El polinomio grado 3 iguala casi al GBR, con interpretación matemática directa.
- Gradient Boosting logra máxima precisión, pero sin expresión analítica cerrada.

Síntesis

Regresión Lineal

$$\beta = (X^T X)^{-1} X^T y$$

Solución cerrada. Bajo coste, alto sesgo.

Polinomial Grado 2

$$\varphi: \mathbb{R}^2 \rightarrow \mathbb{R}^6, \quad \hat{\varepsilon} = X\varphi\beta$$

Captura curvatura. 6 parámetros.

Polinomial Grado 3

$$\varphi: \mathbb{R}^2 \rightarrow \mathbb{R}^{10}, \quad \hat{\varepsilon} = X\varphi\beta$$

Mayor flexibilidad. 10 parámetros.

Gradient Boosting

$$F_M = \sum \eta \cdot h_m(x)$$

No paramétrico. Máxima precisión.